

# 1 - Úvod




Michael Šebek  
Automatické řízení 2018



- **Objekt:** konkrétní auto (tamto)



- **Systém:** určitá část objektu, kterou se zabýváme, řídíme,... Motor, spojka, řízení směru (ESC), rychlosti (tempomat), brzdění (ABS,EBS), trakce (TCS), pérování (RSC), emise, spotřeba, HVAC, telematika, infotainment, ... řízení kolony (AHS),...



- **Model:** nějaký vhodný popis (rovnice, diagram, graf, program...)

$$\begin{aligned}\dot{x} &= v \cos \theta \\ \dot{y} &= v \sin \theta \\ \dot{\theta} &= \frac{v}{L} \tan \psi\end{aligned}$$




Figure 2.1: Simulation of the dynamic behavior of a vehicle under hard braking conditions






Figure 1.4: A discrete-time PI controller is added to the engine model to regulate speed




- Různé modely stejného systému pro různé účely: simulace, návrh, ...





## Systémy

- obecné a zvláštní
- soustava
- regulátor, kompenzátor, zákon řízení,
- celkový systém, uzavřená smyčka




## Signály

- nějaká fyzikální veličina  
(pozor: šipka není „drát“)
- vstup, akční zásah, reference
- porucha, rušení: měřená, neměřená
- výstup: řízený, měřený
- vnitřní veličiny (stavy)
- šum měření
- regulační odchylka (míra kvality)








## Přímá vazba (PV, FF)




## Zpětná vazba (ZV, FB)




## Dva stupně volnosti (TDF)




## ZV s poruchou a šumem měření



## + FF od měřené poruchy




## + FF od reference a poruchy





- spojitý (čas) - diskrétní (čas) - vzorkovaný



- SISO - MIMO



- soustředěné - rozložené parametry, dopravní zpoždění
- neproměnný - proměnný v čase
- lineární - nelineární



# Nelineární stavový model

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), t)$$

$$\mathbf{y}(t) = \mathbf{h}(\mathbf{x}(t), \mathbf{u}(t), t)$$



výstup, stav, vstup, čas - obecně vektory

**Stavová rovnice** - vektorová nelineární  
diferenciální rovnice **prvního** řádu

**Výstupní rovnice** - není diferenciální

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_p \end{bmatrix}, \mathbf{f} = \begin{bmatrix} f_1 \\ \vdots \\ f_n \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \mathbf{u} = \begin{bmatrix} u_1 \\ \vdots \\ u_m \end{bmatrix}$$

- řešení závisí na vstupu a počátečním stavu  $\mathbf{x}(t_0^-) = \mathbf{x}_0$  (a na poč. čase)

## Zvláštní případy:

- model nezávisí na posunu v čase,  
je **v čase neproměnný** (TI)
- autonomní** systém, neřízený
- systém typu **statická nelinearita**

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)), \quad \mathbf{x}(0^-) = \mathbf{x}_0$$

$$\mathbf{y}(t) = \mathbf{h}(\mathbf{x}(t), \mathbf{u}(t))$$

$$\longrightarrow \quad \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}), \mathbf{y} = \mathbf{h}(\mathbf{x})$$

$$\longrightarrow \quad \mathbf{y} = \mathbf{h}(\mathbf{u})$$

## Zvláštní typ řešení:

- periodické, tzv. limitní cyklus
- ekvilibrrium**, rovnovážný,  
ustálený stav

$$\mathbf{u}_e(t) = \mathbf{u}_e, \mathbf{x}_e(t) = \mathbf{x}_e \Rightarrow \mathbf{0} = \dot{\mathbf{x}}_e(t) = \mathbf{f}(\mathbf{x}_e(t), \mathbf{u}_e(t))$$



- Linearita (homogennost + aditivnost): obecný lineární systém  $y = \mathcal{S}(u)$  je **lineární** vzhledem k vstupu a výstupu, právě když (při stejných pp.)

$$y_1 = \mathcal{S}(u_1), y_2 = \mathcal{S}(u_2) \Rightarrow y = \mathcal{S}(c_1 u_1 + c_2 u_2) = c_1 y_1 + c_2 y_2$$

- Lineární systémy mají spoustu příjemných vlastností, které umožňují užívat mnoho užitečných nástrojů (frekvenční charakteristika, ...)
- Lineární stavový model má tvar

$$\dot{\mathbf{x}}(t) = \mathbf{A}(t)\mathbf{x}(t) + \mathbf{B}(t)\mathbf{u}(t)$$

$$\mathbf{y}(t) = \mathbf{C}(t)\mathbf{x}(t) + \mathbf{D}(t)\mathbf{u}(t)$$

$$\mathbf{x}(t_0^-) = \mathbf{x}_0$$

LTV

- Je-li navíc časově neproměnný, pak

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{D}\mathbf{u}(t)$$

$$\mathbf{x}(t_0^-) = \mathbf{x}_0$$

LTI

- Co dělat, když náš systém takový není?



- Popisuje vstup, výstup a jejich vyšší derivace, vnitřní veličiny přímo ne
- Předpokládá se, že příslušné derivace existují, alespoň ve smyslu distribucí
- Obecné nelineární IO modely jsou dost divoké, kurz ARI vystačí s

$$\mathbf{D}(\mathbf{y}^{(n)}(t), \dots, \dot{\mathbf{y}}(t), \mathbf{y}(t), t) = \mathbf{N}(\mathbf{u}^{(m)}(t), \dots, \dot{\mathbf{u}}(t), \mathbf{u}(t), t)$$

- a jeho lineárním LTV případem

$$\mathbf{a}_n(t)\mathbf{y}^{(n)}(t) + \dots + \mathbf{a}_1(t)\dot{\mathbf{y}} + \mathbf{a}_0(t)\mathbf{y}(t) = \mathbf{b}_m(t)\mathbf{u}^{(m)}(t) + \dots + \mathbf{b}_1(t)\dot{\mathbf{u}}(t) + \mathbf{b}_0(t)\mathbf{u}(t)$$

jehož řešení závisí na vstupu (včetně jeho příslušných derivací)  
a na počátečních podmínkách  $\mathbf{y}^{(n-1)}(t_0^-), \dots, \dot{\mathbf{y}}(t_0^-), \mathbf{y}(t_0^-)$

- V LTI variantě je to

$$\mathbf{a}_n\mathbf{y}^{(n)}(t) + \dots + \mathbf{a}_1\dot{\mathbf{y}}(t) + \mathbf{a}_0\mathbf{y}(t) = \mathbf{b}_m\mathbf{u}^{(m)}(t) + \dots + \mathbf{b}_1\dot{\mathbf{u}}(t) + \mathbf{b}_0\mathbf{u}(t)$$

s počátečními podmínkami  $\mathbf{y}^{(n-1)}(0^-), \dots, \dot{\mathbf{y}}(0^-), \mathbf{y}(0^-)$





# Lineární aproximace – tzv. linearizace

Automatické řízení - Kybernetika a robotika

- Vybereme **nominální řešení** (trajektorii), ve kterém chceme systém provozovat: referenční trajektorie, limitní cyklus nebo, nejčastěji,
- **ekvilibrium** - tomu říkáme **pracovní bod** nebo **operační bod**
- V okolí nominálního řešení (pracovního bodu) nahradíme nelineární model jeho lineární odchylkovou aproximací - „tečnou dynamikou“
- Často tomu nepřesně říkáme **linearizace**, přesnější je **lineární aproximace** (neboť jsou ještě jiné linearizace, třeba tzv. přesná linearizace)

## Funguje to pokud

- 1) je systém (v provozovaných režimech) skoro lineární nebo
- 2) zůstává blízko pracovního bodu: **malé odchylky**, „malé signály“

V systémech ZV automatického řízení bývá 2) často splněno

- **Aproximace je vždy vztažena k určitému pracovnímu bodu a platí jen pro malé odchylky od něj!**
- Když 1) ani 2) neplatí, přepíná se někdy více regulátorů založených na aproximacích v různých pracovních bodech (tzv. gain scheduling)
- V některých případech aproximace neexistuje nebo je k ničemu
- Někdy aproximaci nechceme/nemůžeme použít (stabilizace kyvadla vs. vztyčení)



# Lineární aproximace - „linearizace“

V okolí nominálního řešení (pracovního bodu) platí

$$\mathbf{x}(t) = \mathbf{x}_p(t) + \Delta\mathbf{x}(t)$$

$$\mathbf{u}(t) = \mathbf{u}_p(t) + \Delta\mathbf{u}(t)$$

$$\mathbf{y}(t) = \mathbf{y}_p(t) + \Delta\mathbf{y}(t)$$

$$\begin{aligned}\dot{\mathbf{x}}(t) &= \dot{\mathbf{x}}_p(t) + \Delta\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}_p(t) + \Delta\mathbf{x}(t), \mathbf{u}_p(t) + \Delta\mathbf{u}(t)) \\ &\stackrel{||}{=} \mathbf{f}(\mathbf{x}_p(t), \mathbf{u}_p(t)) + \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(t) + \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(t) + \text{členy vyšších řádů}\end{aligned}$$

$$\begin{aligned}\mathbf{y}(t) &= \mathbf{y}_p(t) + \Delta\mathbf{y}(t) = \mathbf{g}(\mathbf{x}_p(t) + \Delta\mathbf{x}(t), \mathbf{u}_p(t) + \Delta\mathbf{u}(t)) \\ &\stackrel{||}{=} \mathbf{h}(\mathbf{x}_p(t), \mathbf{u}_p(t)) + \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(t) + \frac{\partial \mathbf{h}}{\partial \mathbf{u}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(t) + \text{členy vyšších řádů}\end{aligned}$$

- kde rozvíjíme nelineární funkce v Taylorovy řady v okolí nominálního řešení (pokud parciální derivace existují)
- Pro **malé odchylky** tak dostáváme **lineární aproximaci**

$$\begin{aligned}\Delta\dot{\mathbf{x}}(t) &= \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(t) + \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(t) \\ \Delta\mathbf{y}(t) &= \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(t) + \frac{\partial \mathbf{h}}{\partial \mathbf{u}} \bigg|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(t)\end{aligned}$$



Nelineární model v okolí nominálního řešení aproximujeme lineárním

$$\begin{array}{lcl} \dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) & \xrightarrow{\mathbf{x}_p(t), \mathbf{u}_p(t)} & \Delta \dot{\mathbf{x}}(t) = \mathbf{A} \Delta \mathbf{x}(t) + \mathbf{B} \Delta \mathbf{u}(t) \\ \mathbf{y}(t) = \mathbf{h}(\mathbf{x}(t), \mathbf{u}(t)) & & \Delta \mathbf{y}(t) = \mathbf{C} \Delta \mathbf{x}(t) + \mathbf{D} \Delta \mathbf{u}(t) \end{array}$$

**Pozor:**  
platí  
pro odchylky,  
ale často  
se píše bez  $\Delta$  !

- kde jsou

$$\mathbf{A} = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)}, \mathbf{B} = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)}, \mathbf{C} = \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)}, \mathbf{D} = \left. \frac{\partial \mathbf{h}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)}$$

Jacobiho matice funkcí  $\mathbf{f}, \mathbf{h}$  vyčíslené v nominálním „bodě“  $(\mathbf{x}_p(t), \mathbf{u}_p(t))$

- Např.

$$\mathbf{A} = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots \\ \vdots & \vdots & \ddots \end{bmatrix}_{\mathbf{x}=\mathbf{x}_p, \mathbf{u}=\mathbf{u}_p}, \dots$$

- jde to i pro časově proměnné systémy,  
stačí všude připsat  $t$  a dostaneme  $\mathbf{A}(t), \mathbf{B}(t), \mathbf{C}(t), \mathbf{D}(t)$



# Lineární aproximace IO modelu

Automatické řízení - Kybernetika a robotika

- V okolní nominálního řešení (pracovního bodu)  $\mathbf{y}_p(t), \dots, \mathbf{y}_p^{(n)}(t), \mathbf{u}_p(t), \dots, \mathbf{u}_p^{(m)}(t)$  můžeme IO model aproximovat lineárním podobně jako stavový
- Vyjádříme  $\mathbf{D}(\mathbf{y}^{(n)}(t), \dots, \dot{\mathbf{y}}(t), \mathbf{y}(t), t) = \mathbf{N}(\mathbf{u}^{(m)}(t), \dots, \dot{\mathbf{u}}(t), \mathbf{u}(t), t)$   
pro  $\mathbf{y}(t) = \mathbf{y}_p(t) + \Delta\mathbf{y}(t), \dots, \mathbf{y}^{(n)}(t) = \mathbf{y}_p^{(n)}(t) + \Delta\mathbf{y}^{(n)}(t),$   
 $\mathbf{u}(t) = \mathbf{u}_p(t) + \Delta\mathbf{u}(t), \dots, \mathbf{u}^{(m)}(t) = \mathbf{u}_p^{(m)}(t) + \Delta\mathbf{u}^{(m)}(t)$

- Použitím Taylorových řad dostáváme postupně

$$\begin{aligned} & \left( \mathbf{D} \Big|_p + \frac{\partial \mathbf{D}}{\partial \mathbf{y}} \Big|_p \Delta\mathbf{y} + \frac{\partial \mathbf{D}}{\partial \dot{\mathbf{y}}} \Big|_p \Delta\dot{\mathbf{y}} + \dots + \frac{\partial \mathbf{D}}{\partial \mathbf{y}^{(n)}} \Big|_p \Delta\mathbf{y}^{(n)} + \text{členy vyšších řádů} \right) \\ &= \left( \mathbf{N} \Big|_p + \frac{\partial \mathbf{N}}{\partial \mathbf{u}} \Big|_p \Delta\mathbf{u} + \frac{\partial \mathbf{N}}{\partial \dot{\mathbf{u}}} \Big|_p \Delta\dot{\mathbf{u}} + \dots + \frac{\partial \mathbf{N}}{\partial \mathbf{u}^{(m)}} \Big|_p \Delta\mathbf{u}^{(m)} + \text{členy vyšších řádů} \right) \end{aligned}$$

$$\frac{\partial \mathbf{D}}{\partial \mathbf{y}} \Big|_p \Delta\mathbf{y} + \frac{\partial \mathbf{D}}{\partial \dot{\mathbf{y}}} \Big|_p \Delta\dot{\mathbf{y}} + \dots + \frac{\partial \mathbf{D}}{\partial \mathbf{y}^{(n)}} \Big|_p \Delta\mathbf{y}^{(n)} \cong \frac{\partial \mathbf{N}}{\partial \mathbf{u}} \Big|_p \Delta\mathbf{u} + \frac{\partial \mathbf{N}}{\partial \dot{\mathbf{u}}} \Big|_p \Delta\dot{\mathbf{u}} + \dots + \frac{\partial \mathbf{N}}{\partial \mathbf{u}^{(m)}} \Big|_p \Delta\mathbf{u}^{(m)}$$

- Lineární aproximace je  $\mathbf{a}_0 \Delta\mathbf{y} + \mathbf{a}_1 \Delta\dot{\mathbf{y}} + \dots + \mathbf{a}_n \Delta\mathbf{y}^{(n)} = \mathbf{b}_0 \Delta\mathbf{u} + \mathbf{b}_1 \Delta\dot{\mathbf{u}} + \dots + \mathbf{b}_m \Delta\mathbf{u}^{(m)}$



## Proměnný v čase

- Nelineární

$$\mathbf{x}(k+1) = \mathbf{f}(\mathbf{x}(k), \mathbf{u}(k), k)$$

$$\mathbf{y}(k) = \mathbf{h}(\mathbf{x}(k), \mathbf{u}(k), k)$$

- Lineární

$$\mathbf{x}(k+1) = \mathbf{A}(k)\mathbf{x}(k) + \mathbf{B}(k)\mathbf{u}(k)$$

$$\mathbf{y}(k) = \mathbf{C}(k)\mathbf{x}(k) + \mathbf{D}(k)\mathbf{u}(k)$$

- Počáteční stav

$$\mathbf{x}(k_0) = \mathbf{x}_0$$

- Rovnovážný, ustálený stav - **ekvilibrium**

$$\mathbf{u}_e(k) = \mathbf{u}_e, \mathbf{x}_e(k) = \mathbf{x}_e \Rightarrow \mathbf{x}_e = \mathbf{f}(\mathbf{x}_e, \mathbf{u}_e)$$

## Neproměnný v čase

$$\mathbf{x}(k+1) = \mathbf{f}(\mathbf{x}(k), \mathbf{u}(k))$$

$$\mathbf{y}(k) = \mathbf{h}(\mathbf{x}(k), \mathbf{u}(k))$$

$$\mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k)$$

$$\mathbf{y}(k) = \mathbf{C}\mathbf{x}(k) + \mathbf{D}\mathbf{u}(k)$$

$$\mathbf{x}(0) = \mathbf{x}_0$$



# Diskrétní model vstup-výstup (vnější)

Automatické řízení - Kybernetika a robotika

- Nelineární

$$\mathbf{D}(\mathbf{y}(k+n), \dots, \mathbf{y}(k+1), \mathbf{y}(k), k) = \mathbf{N}(\mathbf{u}(k+m), \dots, \mathbf{u}(k+1), \mathbf{u}(k), k)$$

- Lineární v čase proměnný (LTV)

$$\begin{aligned} \mathbf{a}_n(k)\mathbf{y}(k+n) + \dots + \mathbf{a}_1(k)\mathbf{y}(k+1) + \mathbf{a}_0(k)\mathbf{y}(k) \\ = \mathbf{b}_m(k)\mathbf{u}(k+m) + \dots + \mathbf{b}_1(k)\mathbf{u}(k+1) + \mathbf{b}_0(k)\mathbf{u}(k) \end{aligned}$$

s „počátečními“ podmínkami  $\mathbf{y}(k+n-1), \dots, \mathbf{y}(k+1), \mathbf{y}(k)$

- Lineární v čase neproměnný (LTI)

$$\begin{aligned} \mathbf{a}_n\mathbf{y}(k+n) + \dots + \mathbf{a}_1\mathbf{y}(k+1) + \mathbf{a}_0\mathbf{y}(k) \\ = \mathbf{b}_m\mathbf{u}(k+m) + \dots + \mathbf{b}_1\mathbf{u}(k+1) + \mathbf{b}_0\mathbf{u}(k) \end{aligned}$$

s „počátečními“ podmínkami  $\mathbf{y}(n-1), \dots, \mathbf{y}(1), \mathbf{y}(0)$



# Lineární aproximace diskrétních modelů

Automatické řízení - Kybernetika a robotika

$$\begin{aligned}\mathbf{x}(k+1) &= \mathbf{f}(\mathbf{x}(k), \mathbf{u}(k)) \\ \mathbf{y}(k) &= \mathbf{h}(\mathbf{x}(k), \mathbf{u}(k))\end{aligned}$$

$$\begin{aligned}\mathbf{x}(k) &= \mathbf{x}_p(k) + \Delta\mathbf{x}(k) \\ \mathbf{u}(k) &= \mathbf{u}_p(k) + \Delta\mathbf{u}(k) \\ \mathbf{y}(k) &= \mathbf{y}_p(k) + \Delta\mathbf{y}(k)\end{aligned}$$

$$\mathbf{x}(k+1) = \mathbf{x}_p(k+1) + \Delta\mathbf{x}(k+1) = \mathbf{f}(\mathbf{x}_p(k) + \Delta\mathbf{x}(k), \mathbf{u}_p(k) + \Delta\mathbf{u}(k))$$

$$\cong \mathbf{f}(\mathbf{x}_p(k), \mathbf{u}_p(k)) + \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(k) + \left. \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(k)$$

$$\mathbf{y}(k) = \mathbf{y}_p(k) + \Delta\mathbf{y}(k) = \mathbf{g}(\mathbf{x}_p(k) + \Delta\mathbf{x}(k), \mathbf{u}_p(k) + \Delta\mathbf{u}(k))$$

$$\cong \mathbf{h}(\mathbf{x}_p(k), \mathbf{u}_p(k)) + \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(k) + \left. \frac{\partial \mathbf{h}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(k)$$

Je to jako u spojitých modelů: čas je sice diskrétní, ale hodnoty jsou spojité (kontinuum)

$$\begin{aligned}\Delta\mathbf{x}(k+1) &\cong \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(k) + \left. \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(k) \\ \Delta\mathbf{y}(k) &\cong \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{x}(k) + \left. \frac{\partial \mathbf{h}}{\partial \mathbf{u}} \right|_{(\mathbf{x}_p, \mathbf{u}_p)} \Delta\mathbf{u}(k)\end{aligned}$$